



Aplicación de la Metodología KDD a una Cadena Internacional de Hoteles

**Introducción a Data Mining · Maestría en Explotación de Datos
y Gestión del Conocimiento · Universidad Austral**

18 de junio de 2026

Índice

Introducción	5
Limpieza de Datos (<i>Data Cleaning</i>)	6
Problemas identificados en el caso	6
Tratamiento propuesto	6
Integración de Datos (<i>Data Integration</i>)	8
Problema concreto	8
Implementación propuesta	8
Selección de Datos (<i>Data Selection</i>)	9
Para el Problema 1: Anuncios durante la estadía	9
Para el Problema 2: Mailing personalizado	9
Transformación de Datos (<i>Data Transformation</i>)	10
Transformaciones sobre el perfil del huésped	10
Transformaciones sobre el comportamiento en estadía (P1)	10
Transformaciones sobre el historial de estadías (P2)	11
Minería de Datos (<i>Data Mining</i>)	12
Problema 1a: Anuncios durante la estadía	12
Reglas de Asociación	12
Clasificación	12
Clasificación Incremental con Naïve Bayes	13
Clustering	13
Problema 1b: Primeros Días de la Estadía (<i>Cold Start</i>)	13
Problema 2: Mailing Personalizado	14
Clustering de Hoteles	14
Caracterización y Discriminación por Segmento	14
Clasificación para Ranking	15
Minería de Texto y Análisis de Sentimiento	15
Evaluación de Patrones (<i>Pattern Evaluation</i>)	17
Metodología de evaluación de los modelos predictivos	17
Presentación del Conocimiento (<i>Knowledge Presentation</i>)	19
Entregables para el Problema 1	19
Entregables para el Problema 2	19
Entregables para la Gerencia	19
Consideraciones de Privacidad y Ética	20
Resumen	21

Referencias

22

Integrantes del grupo

Ulises Catalano

Juan Pablo Fara

Marcos Maceo

Andres Rodriguez

Introducción

El presente trabajo tiene por objetivo desarrollar la metodología KDD (*Knowledge Discovery from Data*) aplicada al caso de una cadena internacional de hoteles que busca extraer conocimiento útil a partir de los datos generados por sus huéspedes.

La metodología KDD, descrita por Han et al. (2012) como un proceso iterativo de siete pasos, constituye el marco conceptual que organiza el análisis. El proceso abarca desde la preparación de los datos hasta la presentación del conocimiento obtenido, con la minería de datos como etapa central.

Los problemas de negocio identificados en el caso son dos:

- **Problema 1 (P1):** Determinar qué anuncios de televisión enviar a cada huésped durante su estadía, con especial atención a los primeros días, cuando la información disponible sobre el huésped es escasa (*cold start*).
- **Problema 2 (P2):** Seleccionar qué hoteles de la cadena incluir en el mailing personalizado enviado a ex huéspedes con el fin de generar nuevas reservas.

Tabla 1: Fuentes de datos disponibles en la cadena hotelera

Sistema	Datos generados
Check-in	Demografía (edad, origen, idioma, ocupación) y cuestionario de preferencias
Tarjeta de acceso	Uso de gimnasio, piscina y bares (servicios gratuitos)
Transacciones	Compras en bares, restaurantes y tiendas del hotel
Canal de TV	Anuncios mostrados e interacciones del huésped
Formulario de salida	Evaluaciones 1-5 por ítem y comentarios en texto libre
Histórico inter-hotel	Estadías previas en cualquier hotel de la cadena

Nota. Elaboración propia a partir del enunciado del caso.

Limpieza de Datos (*Data Cleaning*)

La limpieza de datos consiste en la eliminación de ruido e inconsistencias previo a cualquier análisis; los errores no tratados pueden conducir a la derivación de patrones erróneos (Han et al., 2012).

Problemas identificados en el caso

A continuación se detallan las principales fuentes de imperfección de los datos en el contexto hotelero:

- **Valores faltantes en el cuestionario inicial:** una proporción de huéspedes omite responder preguntas al momento del check-in, lo que genera registros incompletos en el perfil demográfico.
- **Formularios de evaluación parciales:** al momento del checkout, es frecuente que determinadas preguntas queden sin respuesta, en especial aquellas que requieren comentarios escritos.
- **Comentarios en múltiples idiomas:** el texto libre del formulario de evaluación puede estar redactado en español, inglés, portugués u otros idiomas, lo que requiere un tratamiento previo antes de cualquier análisis textual.
- **Inconsistencias entre sistemas de distintos países:** los hoteles de la cadena pueden operar con formatos de fecha, monedas y nomenclaturas de servicios distintas según el país de operación.
- **Registros duplicados de huéspedes:** un mismo huésped puede aparecer registrado con variantes de su nombre o documento en distintas propiedades de la cadena.

Tratamiento propuesto

- Los **campos numéricos faltantes** (edad, monto de gasto) se estiman mediante **imputación por k-vecinos más cercanos** (kNN): el valor ausente se completa a partir del promedio observado en los huéspedes de perfil demográfico más cercano según una métrica de distancia sobre los atributos disponibles. Esta técnica se prefiere a la imputación por la media global porque preserva la estructura local de los datos y no aplanar la variabilidad del atributo.
- Las **inconsistencias de formato** entre países se resuelven mediante reglas de estandarización aplicadas durante la importación de datos de cada hotel (fechas en formato ISO, montos convertidos a una moneda de referencia única).
- Los **duplicados** se resuelven mediante la construcción de un identificador canónico del huésped (`guest_id`) a partir de reglas de **vinculación de registros** (*record linkage*). La combinación (código de país, número de pasaporte) constituye la regla principal, ya que el número de pasaporte es único únicamente dentro de un mismo país y su combinación con el código de país resulta indispensable en un contexto internacional. No obstante, dado que en la práctica existen huéspedes sin pasaporte, documentos vencidos o modificados y errores de carga, la vinculación se complementa con atributos adicionales (correo electrónico, teléfono, fecha de nacimiento y nombre normalizado) para reconciliar los registros que refieren a una misma persona. El correo electrónico,

en particular, se emplea como señal de apoyo y no como clave única, dado que los huéspedes pueden modificarlo o compartirlo entre miembros de una familia.

- Los **comentarios en texto libre** se someten a una normalización de idioma y ortografía antes de cualquier procesamiento analítico.

Integración de Datos (*Data Integration*)

La integración de datos consiste en la combinación de múltiples fuentes en un repositorio unificado; su resultado típico es un *data warehouse*, repositorio centralizado que consolida información de diversas fuentes bajo un esquema común (Han et al., 2012).

Problema concreto

Los datos de la cadena hotelera se encuentran distribuidos entre distintos hoteles y países, con sistemas informáticos posiblemente incompatibles entre sí. A fin de que el proceso de minería de datos opere a nivel de toda la cadena, es necesario consolidar todas las fuentes en un único repositorio centralizado.

Implementación propuesta

Se propone la construcción de un *data warehouse* centralizado que integre las siguientes fuentes: sistema de check-in, tarjeta de acceso, sistema de transacciones, formularios de evaluación e historial de estadias anteriores. La clave de integración entre fuentes es el identificador canónico del huésped (`guest_id`) construido en el paso anterior mediante vinculación de registros, cuya regla principal es la combinación (código de país, número de pasaporte).

El proceso de extracción, transformación y carga (ETL) opera de forma periódica, con la importación de los registros generados por cada hotel durante el período anterior y su consolidación bajo el esquema unificado del *data warehouse*. Esto garantiza que la información disponible para el análisis sea consistente y comparable entre todas las propiedades de la cadena.

Selección de Datos (*Data Selection*)

La selección de datos consiste en la recuperación, desde el repositorio integrado, de los atributos y registros pertinentes para la tarea de análisis específica (Han et al., 2012). No todos los datos disponibles resultan relevantes para cada problema; esta etapa permite reducir la dimensionalidad y descartar los atributos no pertinentes para cada tarea.

Para el Problema 1: Anuncios durante la estadía

Para cada huésped activo, se seleccionan los siguientes atributos:

- Perfil demográfico: edad, país de origen, idioma, tipo de viaje (individual, pareja, familia).
- Respuestas al cuestionario inicial completado al check-in.
- Registros de uso de la tarjeta de acceso durante la estadía en curso: servicios utilizados, frecuencia y franja horaria.
- Historial de compras y servicios de estadías anteriores en la cadena.

Los huéspedes con estadía de una única noche se marcan con un atributo `estadía_corta` y se tratan como un segmento especial, en lugar de descartarlos por completo: si bien el tiempo disponible es insuficiente para el aprendizaje de preferencias durante la estadía (Problema 1), su información conserva valor para el mailing posterior y el análisis de conversiones rápidas (Problema 2). Asimismo, se descartan los atributos con una proporción elevada de valores faltantes que no puedan estimarse de forma confiable.

Para el Problema 2: Mailing personalizado

Del historial completo de la cadena se seleccionan:

- Secuencia de hoteles visitados por cada huésped (tipo, ubicación geográfica, temporada del año).
- Evaluaciones promedio otorgadas por tipo de hotel en estadías previas.
- Tiempo transcurrido desde la última estadía, a fin de identificar huéspedes con baja actividad reciente.

Transformación de Datos (*Data Transformation*)

La transformación de datos consiste en convertir y consolidar los datos en formatos aptos para los algoritmos de minería, mediante operaciones de resumen, agregación y normalización (Han et al., 2012).

Transformaciones sobre el perfil del huésped

Tabla 2: Transformaciones sobre el perfil demográfico del huésped

Atributo original	Transformacion	Atributo resultante
Edad (valor continuo)	Discretización en rangos	joven (<30) / adulto (30-60) / senior (>60)
Gasto total	Normalización entre hoteles y monedas	Valor relativo comparable entre propiedades
País de origen	Agrupación en regiones geográficas	Europa / América Latina / Asia / Otros

Nota. Elaboración propia.

Transformaciones sobre el comportamiento en estadía (P1)

Tabla 3: Transformaciones sobre el comportamiento del huésped durante la estadía

Atributo original	Transformacion	Atributo resultante
Registros de acceso por servicio	Agregación como frecuencia de uso por día de estadía	visitas_gimnasio/día, visitas_piscina/día, etc.
Montos de compra por categoría	Proporción sobre el gasto total	ratio_gastronomía, ratio_tienda, ratio_bebidas
Hora de actividad registrada	Discretización en franjas horarias	mañana / tarde / noche

Nota. Elaboración propia.

Si los registros de la tarjeta de acceso incluyeran también la **hora de egreso** de cada servicio, esta agregación podría refinarse calculando el **tiempo promedio de permanencia por día** en lugar de la mera frecuencia de acceso, dado que dos huéspedes con igual número de visitas pueden registrar permanencias muy dispares (por ejemplo, un minuto frente a dos horas en el gimnasio). Esta variante queda supeditada a la disponibilidad de los registros de egreso, que no necesariamente se relevan en el caso.

Transformaciones sobre el historial de estadías (P2)

- Los **tipos de hotel visitados** se expresan como frecuencia relativa de cada tipo (playa, ciudad, montaña) sobre el total de estadías del huésped.
- Las **evaluaciones** por ítem se agregan como promedio por categoría (gastronomía, instalaciones, atención al cliente).

El resultado de esta etapa es un vector de atributos numéricos por huésped, apto para ser procesado por los modelos de minería descriptos en el paso siguiente.

Minería de Datos (*Data Mining*)

La minería de datos constituye el paso central del proceso KDD: en esta etapa se aplican métodos inteligentes sobre los datos preparados para extraer patrones de interés, clasificados en tareas **descriptivas** (caracterización, discriminación, asociación, clustering) y **predictivas** (clasificación, regresión) (Han et al., 2012).

Problema 1a: Anuncios durante la estadía

Reglas de Asociación

La minería de reglas de asociación, descrita en Han et al. (2012), permite identificar conjuntos de ítems que co-ocurren frecuentemente en las transacciones. En el contexto del caso, la unidad de análisis es cada estadía: los “ítems” son los servicios utilizados y los productos adquiridos mediante la tarjeta de acceso.

Del historial de transacciones de toda la cadena se extraen reglas del tipo:

- $\{\text{usa_gimnasio}, \text{compra_agua_mineral}\} \Rightarrow \text{interesado_en_spa}$ [$\text{support} = 2\%$, $\text{confidence} = 65\%$]
- $\{\text{visita_bar_nocturno}, \text{compra_snacks}\} \Rightarrow \text{interesado_en_show_nocturno}$ [$\text{support} = 3\%$, $\text{confidence} = 70\%$]

Al registrarse un nuevo evento en la tarjeta de acceso, estas reglas permiten identificar en tiempo real la categoría de anuncio más pertinente para el huésped. Las reglas que no superen los umbrales mínimos de *support* y *confidence* son descartadas en el paso de evaluación (Han et al., 2012), a fin de evitar recomendaciones basadas en coincidencias estadísticas sin sustento real.

Clasificación

La clasificación es definida por Han et al. (2012) como el proceso de construcción de un modelo que describe y distingue clases de datos a partir de un conjunto de entrenamiento. En el presente caso, el modelo se construye sobre el historial de huéspedes anteriores con los siguientes elementos:

- **Entrada:** perfil del huésped (atributos demográficos y de comportamiento transformados en el paso anterior).
- **Salida:** categoría de anuncio con la que el huésped interactuó en estadías previas.

El modelo resultante se representa como un **árbol de decisión** (Han et al., 2012), cuyas ramas expresan reglas interpretables por el equipo de marketing, del tipo: “*si el huésped pertenece al grupo etario senior y utilizó el spa, mostrar anuncio de gastronomía; si pertenece al grupo joven y asistió al gimnasio, mostrar anuncio de actividades deportivas.*” Con el perfil actualizado del huésped al término de cada día, el árbol predice la categoría de anuncio más relevante para el día siguiente.

La elección del **árbol de decisión** como modelo principal se justifica por la interpretabilidad de sus reglas IF-THEN, requisito central dado que el equipo de marketing debe comprender

y validar el criterio de cada recomendación. Frente a las alternativas estudiadas en la materia, el árbol resulta preferible a **k-vecinos más cercanos** (kNN): este, al ser un método perezoso (*lazy*), exige conservar todo el historial y calcular distancias en tiempo de inferencia, lo que encarece la respuesta en tiempo real. Asimismo, el árbol ofrece una explicación más transparente que **Naïve Bayes**, cuyas probabilidades condicionales resultan menos accionables para un usuario de negocio.

Clasificación Incremental con Naïve Bayes

El perfil del huésped se actualiza al término de cada día de estadía, lo que hace de **Naïve Bayes** un complemento natural del árbol de decisión: se trata de un clasificador **incremental y de bajo costo computacional**, que recalcula las probabilidades a posteriori de cada categoría de anuncio a medida que se incorporan nuevos registros de uso de la tarjeta de acceso, sin necesidad de reentrenar el modelo completo. Bajo el supuesto de independencia condicional entre atributos, estima

$$P(\text{categoría} \mid \text{perfil}) \propto P(\text{categoría}) \prod_i P(x_i \mid \text{categoría}).$$

De este modo, el árbol aporta la regla interpretable que valida el equipo de marketing, mientras que Naïve Bayes provee una estimación probabilística que se ajusta día a día durante la estadía.

Clustering

El análisis de clustering, descrito en Han et al. (2012), permite agrupar objetos por similitud sin necesidad de etiquetas previas. En el presente caso, se emplea para segmentar a los huéspedes activos de acuerdo con su perfil de comportamiento. Cada segmento resultante tiene asociado un ranking de categorías de anuncios, construido a partir del historial de interacciones de huéspedes con perfil similar. Esta técnica resulta de especial utilidad cuando el historial individual de un huésped es aún escaso.

Problema 1b: Primeros Días de la Estadía (*Cold Start*)

Al momento de la llegada, ningún huésped dispone de historial conductual de la estadía actual. Conviene, no obstante, distinguir dos situaciones según la relación previa del huésped con la cadena:

- **Huésped nuevo en la cadena:** solo se cuenta con los datos demográficos relevados en el check-in, las respuestas al cuestionario inicial, el tipo de viaje, el hotel actual y la duración esperada de la estadía.
- **Huésped recurrente:** aunque no existan datos de la estadía en curso, sí se dispone de su historial conductual previo en otros hoteles de la cadena (servicios utilizados, compras, evaluaciones, tipos de hotel visitados y respuestas pasadas a promociones), que constituye una base mucho más rica para la sugerencia inicial.

Este subproblema responde al requerimiento explícito del caso de ofrecer una sugerencia razonable durante los primeros días, cuando el sistema dispone de escasas oportunidades de aprender los hábitos del huésped en la estada actual.

La estrategia propuesta opera en dos fases:

Fase 1, Día 1: mediante las técnicas de **caracterización y discriminación** (Han et al., 2012), se analiza el historial de huéspedes anteriores para identificar qué rasgos demográficos distinguen a los grupos con respuesta diferenciada por categoría de anuncio. El resultado es un conjunto de segmentos predefinidos sobre la base demográfica:

- Familia con hijos → anuncios de actividades infantiles y excursiones familiares.
- Pareja joven → anuncios de vida nocturna y actividades de aventura.
- Adulto mayor con viaje individual → anuncios de gastronomía y tratamientos de spa.

Para el **huésped recurrente**, esta segmentación demográfica se combina desde el Día 1 con su historial conductual previo en la cadena, lo que permite una recomendación inicial más ajustada que la basada únicamente en el perfil demográfico.

Fase 2, Día 2 en adelante: a medida que se acumulan registros de uso de la tarjeta de acceso, las reglas de asociación y el árbol de clasificación se incorporan de forma progresiva. El sistema combina ambas fuentes de información, con mayor peso asignado a los datos conductuales reales a medida que estos se vuelven disponibles.

Problema 2: Mailing Personalizado

El desafío central de este problema radica en que los huéspedes, en la mayoría de los casos, no repiten exactamente el mismo hotel, sino que buscan variedad dentro de un estilo o tipo de experiencia preferida.

Clustering de Hoteles

En primer lugar, se agrupan los hoteles de la cadena por sus características objetivas: tipo de entorno (playa, ciudad, montaña), categoría (lujo, estándar, boutique) y perfil de actividades disponibles. Cada cluster resultante representa un tipo de experiencia hotelera. El objetivo es recomendar el **tipo** de hotel adecuado para el perfil del huésped, sin limitarse a la misma propiedad visitada con anterioridad.

Caracterización y Discriminación por Segmento

Para cada segmento de huéspedes identificado en P1, se aplican técnicas de **caracterización** (Han et al., 2012) con el fin de describir qué tipos de hoteles frecuenta ese segmento con mayor asiduidad. Por ejemplo:

- Segmento “familias”: predominio de visitas en hoteles de playa con actividades para niños.
- Segmento “viajeros de negocios”: predominio de visitas en hoteles de ciudad de categoría superior.

Del análisis de **discriminación** entre segmentos se derivan reglas simples de asignación: “*huésped del segmento $X \rightarrow$ enviar publicaciones de hoteles del cluster Y .*”

Clasificación para Ranking

A fin de refinar la selección, se construye un clasificador que, dado el perfil completo de un huésped, predice la probabilidad de interés en cada tipo de hotel. La salida es un ranking de tipos de hotel por probabilidad estimada de reserva, a partir del cual se seleccionan los tres primeros para incluir en el mailing. Las evaluaciones negativas registradas en estadías previas operan como señal de exclusión: ante una calificación baja en un tipo de hotel, su posición en el ranking se reduce de forma proporcional.

La tarea exige un modelo que estime de forma directa una probabilidad por tipo de hotel. **Naïve Bayes** ofrece esa estimación probabilística de manera natural y eficiente, mientras que el **árbol de decisión** aporta la regla de asignación interpretable por el equipo de marketing; **kNN**, por su parte, permite recomendar a partir de los huéspedes históricamente más similares, a costa de un mayor costo de cómputo en inferencia. Combinar un modelo interpretable con uno probabilístico equilibra transparencia y precisión en la confección del ranking.

Minería de Texto y Análisis de Sentimiento

El formulario de salida constituye una fuente de datos infrautilizada: además de las evaluaciones numéricas 1-5 por ítem, contiene **comentarios en texto libre** que expresan la opinión del huésped en lenguaje natural. Su explotación mediante **minería de texto** aporta una señal de calidad que retroalimenta a ambos problemas de negocio.

Sobre los comentarios normalizados en el paso de limpieza se aplica el siguiente procesamiento:

- **Vectorización** del texto mediante una representación de bolsa de palabras (*bag-of-words*) sobre los términos relevantes, previa tokenización y eliminación de palabras vacías.
- **Clasificación de sentimiento** (positivo / neutro / negativo) mediante un clasificador **Naïve Bayes**, modelo ampliamente utilizado para la categorización de texto por su eficiencia y buen desempeño en espacios de alta dimensión. Las evaluaciones numéricas 1-5 proveen las etiquetas de entrenamiento, lo que permite construir el modelo sin necesidad de un etiquetado manual.
- **Extracción de aspectos**: identificación de los temas mencionados con mayor frecuencia en los comentarios negativos (limpieza, atención, gastronomía, ruido), a fin de localizar el origen de la insatisfacción.

El conocimiento extraído alimenta los dos problemas:

- En **P1**, el sentimiento y los aspectos detectados evitan recomendar durante la estadía servicios sobre los que el huésped ya expresó insatisfacción, y permiten priorizar los valorados positivamente.
- En **P2**, el sentimiento agregado por hotel y por tipo de hotel refina el ranking del mailing: un comentario negativo recurrente sobre un tipo de experiencia reduce su

prioridad, más allá de la calificación numérica.

Evaluación de Patrones (*Pattern Evaluation*)

Han et al. (2012) establecen que no todos los patrones descubiertos por un sistema de minería de datos resultan de interés. Un patrón es considerado interesante si cumple cuatro condiciones: es fácilmente comprensible por los usuarios, es válido en datos nuevos con cierto grado de certeza, es potencialmente útil y resulta novedoso. Las métricas objetivas definidas por los autores para evaluar patrones incluyen el *support*, la *confidence*, la *accuracy* y la *coverage*.

Metodología de evaluación de los modelos predictivos

Los modelos de clasificación empleados (árbol de decisión, Naïve Bayes) se evalúan siguiendo la metodología estándar de la disciplina:

- **Partición en entrenamiento, validación y prueba (*test*):** el modelo se ajusta sobre el primer conjunto, se calibra sobre el segundo y se mide sobre el tercero, de modo que la estimación del desempeño se realice siempre sobre datos no vistos durante el entrenamiento.
- **Validación cruzada de k particiones (*k-fold cross-validation*):** ante una cantidad limitada de datos etiquetados, el conjunto se divide en k subconjuntos y se entrena k veces, lo que produce una estimación del desempeño más robusta y de menor varianza.
- **Matriz de confusión:** a partir de los verdaderos y falsos positivos y negativos se derivan métricas más informativas que la *accuracy* global: **precision**, **recall** (sensibilidad) y su media armónica **F1**, particularmente relevantes ante clases desbalanceadas, situación habitual cuando una categoría de anuncio es mucho menos frecuente que el resto.

Tabla 4: Métricas de evaluación de patrones por problema

Métrica	Qué mide	Umbral y uso	Problema
Support	Frecuencia de la regla en el historial de estadías	Descartar reglas con $\text{support} < 1\%$ de estadías	P1
Confidence	Certeza condicional de la regla de asociación	Descartar reglas con $\text{confidence} < 50\%$	P1
Accuracy	Proporción de clasificaciones correctas del árbol de decisión	Evaluar sobre datos no utilizados en el entrenamiento	P1
Precision	Proporción de recomendaciones positivas que resultan acertadas	Priorizar cuando el costo de un anuncio irrelevante es alto	P1/P2
Recall (sensibilidad)	Proporción de casos de interés real efectivamente detectados	Priorizar para no omitir huéspedes interesados (costo del FN)	P1/P2

F1	Media armónica entre precision y recall	Métrica de resumen ante clases desbalanceadas	P1/P2
Coverage	Proporción de huéspedes para los que el modelo genera una recomendación	El sistema debe cubrir al menos el 80 % de los huéspedes activos	P1
Accuracy del clasificador	Predicciones correctas de interés en tipo de hotel	Evaluar con validación cruzada sobre datos no utilizados en el entrenamiento	P2
Tasa de conversión	Reservas generadas sobre el total de mailings enviados	Comparar contra campaña de mailing no personalizada	P2

Nota. Las métricas de *support*, *confidence*, *accuracy* y *coverage* se definen en Han et al. (2012). Elaboración propia.

El riesgo principal en esta etapa es el **sobreajuste** (*overfitting*): un modelo que memoriza el conjunto de entrenamiento (un árbol excesivamente profundo es el caso típico) alcanza una *accuracy* elevada en entrenamiento pero generaliza mal sobre huéspedes nuevos. Para mitigarlo se aplica **poda** (*pruning*) del árbol y se comparan sistemáticamente las métricas de entrenamiento y de prueba: una brecha amplia entre ambas es señal de sobreajuste. Asimismo, la evaluación es **sensible al costo**: omitir a un huésped potencialmente interesado (falso negativo) tiene un costo de oportunidad distinto al de mostrar un anuncio irrelevante (falso positivo), por lo que el umbral de decisión se calibra en función de esa asimetría y no únicamente para maximizar la *accuracy* global.

Presentación del Conocimiento (*Knowledge Presentation*)

La presentación del conocimiento tiene por objetivo comunicar los resultados del proceso de minería de forma comprensible y accionable para los usuarios finales, quienes en la mayoría de los casos no poseen formación técnica en el área (Han et al., 2012).

Entregables para el Problema 1

El sistema de recomendación de anuncios presenta sus resultados de la siguiente forma:

- Indicación habitación por habitación del anuncio a emitir, con una justificación en lenguaje natural: *“Se muestra anuncio de spa dado que el huésped visitó el gimnasio en tres oportunidades y adquirió agua mineral.”*
- Las reglas IF-THEN derivadas del árbol de decisión se entregan al equipo de marketing en formato legible, sin requerir formación técnica en minería de datos.
- **Seguimiento de efectividad por anuncio:** para cada anuncio emitido se registra si el huésped efectivamente utilizó el servicio recomendado, el tiempo transcurrido entre la emisión del anuncio y la acción, y si se realizó una compra asociada. Esto permite calcular una tasa de conversión por regla, que retroalimenta la etapa de evaluación de patrones: las reglas con conversión sistemáticamente baja se descartan o reemplazan, y el sistema mejora de forma continua. Este mecanismo de retroalimentación refleja el carácter iterativo del proceso KDD (Han et al., 2012).

Entregables para el Problema 2

- Lista exportable por huésped con los tres hoteles recomendados, el puntaje asociado y el motivo de la recomendación.
- Tabla resumen por segmento de huésped: tipo de hotel recomendado a cada segmento y justificación basada en el historial colectivo.

Entregables para la Gerencia

- Gráficos de barras y tablas cruzadas (Han et al., 2012) que muestran qué categorías de anuncios obtienen mayor respuesta por segmento de huésped.
- Evolución mensual de la tasa de conversión del mailing personalizado frente al mailing genérico previo, como indicador del valor agregado del sistema.
- Descripción de los segmentos de huéspedes identificados en lenguaje de negocio, sin recurrir a terminología técnica.

Consideraciones de Privacidad y Ética

El caso involucra el tratamiento de **datos personales sensibles** de huéspedes de distintos países, como documentos de identidad, demografía, comportamiento de consumo y opiniones expresadas en texto libre, por lo que la dimensión ética y legal debe integrarse al proceso KDD (Han et al., 2012, §1.7).

- **Consentimiento y finalidad:** el uso de los datos para recomendación publicitaria y mailing debe estar amparado por el consentimiento del huésped y limitarse a la finalidad informada al momento de la recolección.
- **Marco regulatorio internacional:** al operar la cadena en múltiples países, el tratamiento debe contemplar las normativas de protección de datos aplicables en cada jurisdicción (por ejemplo, el RGPD europeo), lo que condiciona la transferencia de datos entre propiedades.
- **Minería de datos que preserva la privacidad (*privacy-preserving data mining*):** siempre que sea posible, el análisis opera sobre datos **anonimizados o seudonimizados**, disociando el identificador del huésped de los atributos utilizados para el modelado. La segmentación y la recomendación pueden construirse a nivel de perfil agregado, sin exponer la identidad individual.
- **Transparencia y no discriminación:** las reglas de recomendación deben auditarse para evitar sesgos que deriven en un trato discriminatorio por origen, edad u otros atributos protegidos.

Resumen

Tabla 5: Resumen de la aplicación de la metodología KDD al caso hotelero

Paso KDD	Implementación en el caso	Tarea DM	Referencia
1. Data Cleaning	Estimación de faltantes, estandarización de formatos, clave compuesta (país + pasaporte), eliminación de duplicados	N/A	Cap. 1.2, 1.7.1
2. Data Integration	Data warehouse centralizado con perfil unificado por huésped	N/A	Cap. 1.2, 1.3.2
3. Data Selection	Atributos conductuales para P1; historial completo de estadías para P2	N/A	Cap. 1.2
4. Data Transformation	Discretización de edad, normalización de gasto, agregación de uso de servicios, proporciones por categoría	N/A	Cap. 1.2
5. Data Mining (P1)	Asociación + árbol de decisión + Naïve Bayes incremental + clustering; minería de texto/sentimiento sobre comentarios; estrategia en dos fases para cold start	Asociación, Clasificación, Clustering, Caracterización	Cap. 1.4.1-1.4.4
5. Data Mining (P2)	Clustering de hoteles + caracterización por segmento + clasificación (Naïve Bayes/árbol) para ranking; sentimiento por tipo de hotel	Clustering, Caracterización, Clasificación	Cap. 1.4.1, 1.4.3-1.4.4
6. Pattern Evaluation	Support/confidence (asociación); accuracy/precision/recall/F1 con validación cruzada y control de sobreajuste; tasa de conversión (mailing)	N/A	Cap. 1.4.6
7. Knowledge Presentation	Reglas IF-THEN para equipo de TV; lista de hoteles para marketing; gráficos para gerencia	N/A	Cap. 1.4.6, 1.7.2

Nota. Todas las referencias de sección corresponden a Han et al. (2012). Elaboración propia.

Referencias

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.